

HealthSearch — Motor de Busca Híbrido com BM25 e Busca Semântica Vetorial

Ricardo Silva Flores — UNIPÊ — Ciência da Computação
Disciplina: Tendências em Ciência da Computação

1. Problema e objetivo

A HealthTech Solutions mantém protocolos clínicos utilizados por profissionais de saúde durante atendimentos. Nesse contexto, uma busca exclusivamente lexical pode não recuperar documentos quando a consulta utiliza sinônimos ou formas não técnicas — por exemplo, “ataque cardíaco” em vez de “infarto agudo do miocárdio”. Por outro lado, uma busca somente semântica pode reduzir a precisão para códigos, siglas e dosagens, como Cód-ECG-12D e AAS 100mg.

Foi desenvolvido o **HealthSearch**, um protótipo em Streamlit, no arquivo único `healthsearch_app.py`. A solução executa dois motores de recuperação — BM25 e busca semântica vetorial — e combina suas posições usando **Reciprocal Rank Fusion (RRF)**. Essa estratégia é apropriada porque trabalha com ranks, não exigindo que scores produzidos por métodos diferentes estejam na mesma escala.

2. Arquitetura da solução

Fase	Implementação	Decisão técnica
Ingestão e pré-processamento	Seis diretrizes médicas fixas no código; normalização e tokenização	Título e conteúdo são indexados juntos. O pré-processamento converte para minúsculas, remove acentos, caracteres especiais e stopwords. Assim, Cód-ECG-12D é normalizado em <code>cod</code> , <code>ecg</code> e <code>12d</code> .
Motor léxico	BM25Okapi da biblioteca <code>rank_bm25</code>	A barra lateral permite alterar $k_1 \in [0, 3]$ e $b \in [0, 1]$. O índice é recriado conforme os parâmetros. Valores indefinidos são convertidos para zero para evitar erro em casos-limite.
Motor semântico	Embeddings e similaridade de cosseno	O sistema tenta carregar <code>paraphrase-multilingual-MiniLM-L12-v2</code> . Se o modelo não estiver disponível, utiliza simulação vetorial documentada, na qual dimensões representam conceitos médicos e termos relacionados ativam o mesmo conceito.
Fusão híbrida	RRF com $k = 60$	Para cada documento: $Score_{RRF} = \alpha / (60 + Rank_{BM25}) + (1 - \alpha) / (60 + Rank_{Sem})$. O slider α controla o peso do BM25. Documentos com score zero em um motor não recebem rank nem contribuição daquele motor.
Interface	Streamlit	Quatro abas: Léxico, Semântico, Híbrido RRF e Matriz Comparativa. São apresentados Top-1, total de matches léxicos, tempo de busca, tabelas de ranking e gráfico das contribuições no RRF.

O bônus de re-ranking foi implementado como opção: quando habilitado, o sistema usa o Cross-Encoder `ms-marco-MiniLM-L-6-v2` para reordenar apenas os três primeiros resultados do RRF e mostrar variações de posição.

3. Testes e análise

Os testes foram planejados para observar os pontos fortes e fracos de cada estratégia. A consulta “**ataque cardíaco**” deve favorecer a camada semântica, pois o corpus utiliza termos técnicos como “infarto” e “síndrome coronariana”. Em contraste, a consulta “**CÓD-ECG-12D**” tende a favorecer o BM25, já que o código aparece de forma explícita nos documentos 1 e 6. Já “**AAS 100mg**” verifica se a busca semântica aproxima a sigla da expressão “ácido acetilsalicílico”, presente no documento 2.

Resultados da execução: inserir, antes da exportação final em PDF, uma captura própria da aba *Matriz Comparativa* ou do gráfico da aba *Híbrido RRF*. Registrar também o modo exibido na barra lateral: “Embeddings reais” ou “Simulação vetorial”. Os valores de score devem ser retirados da execução local, pois podem mudar conforme o modelo de embeddings esteja disponível.

O RRF reduz os pontos cegos de motores isolados: termos técnicos ou códigos exatos preservam a contribuição lexical, enquanto consultas com sinônimos podem obter contribuição semântica. O parâmetro α permite regular essa preferência: valores próximos de 1 priorizam BM25; valores próximos de 0 priorizam a busca semântica.

4. Limitações e conclusão

O protótipo possui um corpus pequeno, de apenas seis documentos, de modo que os resultados não devem ser interpretados como validação clínica. A ausência de stemming também mantém palavras flexionadas como tokens diferentes. Além disso, os scores podem mudar entre o modo simulado e os embeddings reais. O Cross-Encoder é apresentado apenas como demonstração, pois o modelo escolhido foi treinado predominantemente em inglês.

Ainda assim, o HealthSearch atende ao objetivo proposto: demonstra, em uma interface interativa, como a combinação entre BM25, similaridade vetorial e RRF amplia a cobertura para sinônimos sem abandonar a precisão necessária em siglas e códigos clínicos.

5. Divisão de tarefas

Integrante	Responsabilidades
Ricardo Silva Flores	Desenvolvimento individual: organização do corpus e pré-processamento; implementação do BM25 com parâmetros interativos; motor semântico com embeddings e fallback vetorial; similaridade de cosseno; fusão RRF; interface Streamlit; testes; análise dos resultados; implementação opcional do Cross-Encoder; redação do relatório.